

Modelado Estadístico del Nivel de Estrés en Desarrolladores de Software a partir de Métricas de Productividad y Carga Cognitiva

David Alejandro Cruz Palacios¹, Elvis Paúl García Acevedo¹, Naim Andre Michelena Andrade¹, Emily Mabel Ortega Constante¹, Carlos José Pilatuña Roldan¹, and Mario Alexander Salazar Sema¹

Carrera de Ciencias de la Computación
Facultad de Ingeniería
Universidad Politécnica Salesiana
Quito, Ecuador

{dcruzp5, egarciaa5, nmichelena, eortegac9, cpilatunar,
msalazars2}@est.ups.edu.ec

Resumen

El análisis de los factores que influyen en el nivel de estrés de los desarrolladores de software es relevante debido a su impacto en la productividad, la calidad del código y el bienestar laboral. Este estudio propone un modelo de regresión lineal múltiple para explicar el comportamiento del nivel de estrés utilizando métricas de productividad, desempeño y carga cognitiva. Para ello se empleó un conjunto de datos compuesto por 1000 observaciones y 12 variables predictoras relacionadas con horas de programación, líneas de código producidas, errores detectados, uso de herramientas de inteligencia artificial, duración de tareas y carga cognitiva, entre otras.

Se realizó un proceso de limpieza de datos, análisis exploratorio, estudio de correlaciones y detección de multicolinealidad. Posteriormente, se construyó un modelo mediante un procedimiento de selección de variables por eliminación hacia atrás (Backward Elimination), con el fin de obtener una solución parsimoniosa. Además, se verificaron las principales suposiciones de la regresión lineal y se identificaron observaciones atípicas e influyentes mediante residuales estandarizados, valores de apalancamiento y distancia de Cook.

El modelo final seleccionó cuatro variables explicativas y alcanzó un coeficiente de determinación ajustado de 0.9410. La validación sobre un conjunto de prueba obtuvo un coeficiente de determinación de 0.9270, evidenciando una adecuada capacidad de generalización. Los resultados indican que la carga cognitiva es el predictor más importante del nivel de estrés, mientras que una mayor tasa de éxito en las tareas contribuye a reducirlo.

Palabras clave: Regresión lineal múltiple, Ciencia de Datos, Estrés laboral, Desarrollo de software, Análisis estadístico, Machine Learning, Carga Cognitiva

1. Introducción

El crecimiento exponencial de la industria del software y la adopción de metodologías ágiles de desarrollo han incrementado significativamente la necesidad de comprender los factores psicosociales y técnicos que afectan el desempeño diario de los ingenieros y desarrolladores. Variables como la carga cognitiva, la duración de las tareas, la cantidad de errores producidos (bugs) y el volumen sostenido de trabajo pueden influir de manera drástica sobre el nivel de estrés experimentado durante el ciclo de vida del desarrollo de proyectos tecnológicos.

1.1. Revisión del Estado del Arte

Diversas investigaciones recientes han demostrado que altos niveles de estrés crónico y el agotamiento (burnout) no solo afectan la salud mental del individuo, sino que impactan de manera tangible y negativa la productividad métrica, la mantenibilidad del software y la satisfacción laboral [6]. Estudios como los realizados en el marco de la métrica DORA (DevOps Research and Assessment) indican que un entorno de trabajo con alta carga de errores no resueltos y despliegues problemáticos correlaciona fuertemente con la ansiedad del equipo técnico [7].

Por otro lado, la incorporación reciente de asistentes de Inteligencia Artificial (IA) en la programación introduce una nueva dinámica: si bien pueden reducir el tiempo de tipeo, también pueden incrementar la carga cognitiva al requerir que el desarrollador revise e integre código generado por terceros de manera constante. Entender matemáticamente cómo estas métricas convergen en el nivel de estrés es fundamental para la correcta gestión de proyectos.

1.2. Justificación y Objetivos

La regresión lineal múltiple constituye una de las técnicas estadísticas más robustas y utilizadas para modelar relaciones empíricas entre una variable dependiente de interés y múltiples covariables explicativas [1]. A diferencia de algoritmos de caja negra.^{en} aprendizaje automático, la regresión lineal ofrece una alta interpretabilidad de los coeficientes obtenidos, permitiendo inferir no solo si una variable afecta al fenómeno, sino la magnitud y la dirección exacta de dicho efecto [3].

El objetivo principal de este trabajo de investigación consiste en construir, entrenar y validar un modelo estadístico capaz de identificar qué variables métricas explican de manera sustancial la varianza en el nivel de estrés de los desarrolladores de software. Secundariamente, el estudio busca aplicar buenas prácticas de curación de datos empíricos, validar estadísticamente las suposiciones subyacentes del teorema de Gauss-Markov y evaluar el impacto de observaciones influyentes en la estabilidad del modelo matemático predictivo.

2. Metodología

2.1. Descripción del Conjunto de Datos

Para el desarrollo experimental se utilizó el conjunto de datos *AI Developer Performance Extended*, estructurado formalmente por 1000 instancias (observaciones) independientes que documentan el desempeño de desarrolladores de software bajo distintos entornos y requerimientos.

La variable de respuesta o dependiente (Y) seleccionada para el modelo es:

- **Stress_Level:** Métrica continua que representa el nivel de estrés reportado por el desarrollador.

El espacio de características inicial incluyó un máximo de 12 variables predictoras (X_i):

1. *Hours_Coding*: Horas invertidas activamente en escritura de código.
2. *Lines_of_Code*: Volumen de líneas de código generadas.
3. *Bugs_Found*: Errores identificados durante las pruebas.
4. *Bugs_Fixed*: Errores exitosamente parcheados.
5. *AI_Usage_Hours*: Tiempo de uso de herramientas de asistencia algorítmica.
6. *Sleep_Hours*: Horas de descanso nocturno del individuo.
7. *Cognitive_Load*: Índice métrico del esfuerzo mental requerido.
8. *Task_Success_Rate*: Porcentaje de tareas completadas con éxito.
9. *Coffee_Intake*: Tazas de café consumidas durante la jornada.
10. *Task_Duration_Hours*: Tiempo promedio en resolver una tarea.
11. *Commits*: Número de integraciones de código al repositorio.
12. *Errors*: Advertencias o errores de sintaxis en tiempo de ejecución.

2.2. Fundamentación Matemática del Modelo

El modelo probabilístico de regresión lineal múltiple asume que la variable respuesta Y se relaciona linealmente con un vector de regresores $X_1, X_2, \dots, X_k$ mediante la siguiente ecuación poblacional [2]:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik} + \epsilon_i \quad (1)$$

Donde β_0 es el intercepto, β_j representa el cambio parcial en Y ante el incremento unitario en X_j manteniendo el resto de las variables constantes, y ϵ_i es el término de error aleatorio. Los parámetros β fueron estimados minimizando la suma de los cuadrados de los residuos (Mínimos Cuadrados Ordinarios, OLS).

2.3. Curación y Limpieza de Datos

La fiabilidad de un modelo estadístico depende en gran medida de la calidad del dataset de entrada. Como fase inicial, se ejecutó un algoritmo de identificación de valores nulos o registros incompletos. Las instancias con datos faltantes (NA) fueron descartadas mediante procesos de omisión por lista computacional (`na.omit()`) garantizando así una matriz de diseño de rango completo.

2.4. Selección Algorítmica de Variables

Para cumplir con el marco metodológico, que estipula la obtención de un modelo explicativo con un mínimo de 4 y un máximo de 8 variables predictoras, se desarrolló e implementó un algoritmo iterativo de eliminación hacia atrás (*Backward Elimination*).

El algoritmo parte del modelo "saturado" (12 variables) y en cada iteración evalúa la significancia estadística de los regresores a través de un contraste de hipótesis bilateral sobre los coeficientes:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0 \quad (2)$$

El regresor con el valor-p máximo asociado al estadístico t de Student es eliminado, reentrenando el modelo empírico hasta que el R-cuadrado ajustado (R_{adj}^2) se maximice, logrando el subconjunto óptimo sin violar el límite dimensional establecido.

3. Experimentos y Resultados

3.1. Análisis Exploratorio de Datos (EDA)

Previo a la fase de modelado, se analizó el comportamiento univariante de las métricas. La Tabla 1 resume las principales estadísticas de tendencia central para caracterizar la muestra de desarrolladores.

Tabla 1: Resumen descriptivo del conjunto de datos

Variable	Media	Mediana
Hours_Coding	5.84	6.00
Lines_of_Code	356.20	332.00
Bugs_Found	9.88	10.00
Bugs_Fixed	7.15	7.00
AI_Usage_Hours	2.96	3.00
Sleep_Hours	6.47	6.40
Cognitive_Load	56.93	57.00
Task_Success_Rate	56.58	55.50
Coffee_Intake	3.37	3.00
Stress_Level	66.41	66.00
Task_Duration_Hours	8.70	7.45
Commits	17.25	14.00
Errors	4.54	5.00

3.2. Análisis de Correlación y Multicolinealidad

La presencia de correlaciones elevadas entre variables predictoras (multicolinealidad) infla la varianza de los estimadores OLS, haciéndolos inestables y afectando la interpretabilidad. Para abordar este problema, se calculó la matriz de correlación de Pearson y se diseñó un bucle analítico que inspecciona exhaustivamente pares de variables.

Se estableció un umbral de alerta absoluto de correlación superior a 0.80 ($|r| > 0,80$) para identificar redundancia estructural en los datos. La matriz visual resultante permitió detectar que ciertas dinámicas entre la cantidad de horas programando y líneas de código rozaban márgenes de colinealidad, los cuales debieron ser ajustados en iteraciones posteriores.




Figura 1: Matriz de correlaciones de las variables de productividad y estrés.

3.3. Evolución de la Selección de Características

Tras dividir el conjunto en 80 % para entrenamiento y 20 % de prueba (garantizando así una evaluación no sesgada del modelo), se ejecutó el bucle de *Backward Elimination*. La Tabla 2 ilustra cómo la eliminación progresiva de variables redundantes estabilizó e incluso mejoró marginalmente la penalización del estadístico de bondad de ajuste.

Tabla 2: Evolución iterativa del R-cuadrado ajustado

Iteración	Total Variables	R^2_{Adj} Estimado
1	12	0.9405
2	11	0.9405
3	10	0.9406
4	9	0.9407
5	8	0.9408
6	7	0.9408
7	6	0.9409
8	5	0.9409
9	4	0.9410

El algoritmo se detuvo exitosamente al aislar las 4 variables más críticas, logrando la máxima parsimonia exigida.

3.4. Interpretación del Modelo Final

El subconjunto ganador de variables permitió derivar la siguiente ecuación estocástica predictiva:

$$\begin{aligned}\widehat{Stress} = & 19,892 - 0,0014(Lines_of_Code) \\ & + 0,9002(Cognitive_Load) \\ & - 0,0819(Task_Success_Rate) \\ & + 0,0449(Task_Duration_Hours)\end{aligned}\quad (3)$$

En base a los estimadores calculados:

- **Carga Cognitiva (*Cognitive Load*):** Por cada incremento de una unidad en el índice de carga cognitiva, se proyecta un aumento directo de 0.9002 unidades en el nivel de estrés del desarrollador, manteniendo las demás variables constantes. Su p-valor ($< 0,001$) demuestra que es altamente significativa.
- **Tasa de Éxito (*Task Success Rate*):** Ejerce un factor protector; un aumento del 1 % en el éxito de las tareas se asocia con una reducción de 0.0819 unidades en la métrica de estrés.

Las variables *Líneas de Código* y *Duración de la Tarea* se retuvieron por su valor estructural para sostener el estadístico F y absorber la varianza, a pesar de sus contribuciones marginales individuales más bajas.

3.5. Comprobación de las Suposiciones del Modelo

Para garantizar la validez inferencial de los estimadores se verificaron los supuestos fundamentales:

1. **Normalidad de los Errores:** Se analizó el gráfico cuantil-cuantil (QQ-Plot), donde los residuales observados se alinearon sólidamente sobre la bisectriz teórica, indicando que los errores se distribuyen normalmente, permitiendo confiar en los intervalos de confianza.




Figura 2: Gráfico Cuantil-Cuantil (Q-Q Plot) de los residuales del modelo.

2. **Homocedasticidad:** Al graficar los residuos frente a los valores ajustados ($\hat{Y}$), se evidenció una nube de puntos aleatoria sin patrones de embudo, corroborando que la varianza de los errores es constante en todo el espectro de predicción.




Figura 3: Gráfico de residuales frente a valores ajustados para la verificación de varianza constante.

3.6. Análisis de Observaciones Atípicas e Influyentes

Se implementó un protocolo matemático estricto para mitigar el efecto de datos anómalos. Las observaciones con un residuo estandarizado superior a 2 en valor absoluto se consideraron *outliers*. Para detectar observaciones con alto nivel de apalancamiento (*leverage*), se calcularon los valores h_{ii} de la diagonal de la matriz sombrero (*Hat Matrix*), considerando problemáticos aquellos que superaron el umbral $3(p+1)/n$, donde p representa el número de variables explicativas. Finalmente, la influencia global se midió con la Distancia de Cook (D_i), penalizando observaciones con valor $D_i > 1$. El filtro arrojó resultados destacables: 2 observaciones atípicas estandarizadas (que se amplían a 10 bajo el umbral estudentizado), 14 con elevado *leverage*, y 0 observaciones influyentes bajo el criterio estricto de

Cook. Esto indica una matriz de datos estructuralmente sana.

3.7. Validación Externa y Rendimiento General

El modelo ajustado reportó un $R^2 = 0,9413$ sobre el set de entrenamiento con un Error Estándar Residual de 5.354. Al confrontar el modelo con el 20 % de los datos no vistos durante la partición inicial (fase de prueba/testing), se obtuvo un R-cuadrado predictivo asombrosamente alto:

$$R^2_{test} = 0,9270 \quad (4)$$

Esta leve caída frente al rendimiento de entrenamiento (apenas del 1,4 %) confirma la ausencia total de sobreajuste (*overfitting*).

Adicionalmente, la diferencia observada entre el desempeño sobre el conjunto de entrenamiento ($R^2 = 0,9413$) y el conjunto de prueba ($R^2 = 0,9270$) fue mínima. Esta estabilidad constituye evidencia empírica de que el modelo captura relaciones estructurales reales presentes en los datos y no únicamente patrones específicos de la muestra de entrenamiento.

Desde una perspectiva de aprendizaje estadístico, la baja degradación del rendimiento predictivo sugiere que el proceso de selección de variables logró un equilibrio adecuado entre capacidad explicativa y complejidad del modelo, reduciendo el riesgo de sobreajuste y favoreciendo la generalización hacia nuevas observaciones.

4. Discusión

Los resultados obtenidos evidencian que la regresión lineal múltiple constituye una herramienta eficaz para modelar el nivel de estrés en desarrolladores de software. La Carga Cognitiva se identificó como el predictor más influyente, mientras que la Tasa de Éxito en las Tareas mostró una relación inversa con el estrés. Además, el procedimiento de *Backward Elimination* permitió reducir el modelo de doce a cuatro variables sin afectar significativamente su capacidad explicativa. Finalmente, la validación externa confirmó una adecuada capacidad de generalización y una baja probabilidad de sobreajuste.

5. Conclusiones

El presente estudio culminó exitosamente en la construcción de un modelo de regresión lineal múltiple capaz de mapear con gran certidumbre matemática el nivel de estrés de los desarrolladores de software, logrando explicar más del 94 % de la variabilidad subyacente.

Mediante el desarrollo e integración de un algoritmo sistemático de *Backward Elimination*, el modelo original de doce dimensiones fue exitosamente depurado, convergiendo en un espacio dimensional parsimonioso de cuatro características que satisface los requerimientos técnicos del proyecto. Esta depuración demostró que, en análisis de datos, incorporar múltiples variables redundantes no garantiza mejor precisión.

Estadísticamente, se concluye que la métrica de Carga Cognitiva representa el catalizador psicosocial más agresivo respecto al estrés tecnológico humano. Por su parte, la Tasa de Éxito empodera al desarrollador, amortiguando la curva de tensión mental.

La comprobación exhaustiva de las suposiciones de OLS, junto a la métrica robusta de $R^2 = 0,9270$ en validación externa, garantizan que los hallazgos son estadísticamente consistentes, reproducibles y constituyen una herramienta científica de alto valor para la gerencia de proyectos ágiles.

Disponibilidad de Datos y Materiales

En alineación con las buenas prácticas de la Ciencia Abierta (Open Science) y la Investigación Reproducible, todos los recursos digitales utilizados y generados durante el desarrollo de este proyecto se encuentran respaldados y disponibles públicamente.

El repositorio en línea contiene el conjunto de datos original (*AI Developer Performance Extended*), el dataset resultante tras la curación de datos, y el código fuente completo escrito en lenguaje R (`modelo_estres_devs.R`). Este script incluye las rutinas algorítmicas detalladas para el análisis exploratorio, la matriz de correlación visual, el bucle de iteración del método *Backward Elimination* y los diagnósticos de los residuales estandarizados.

Se invita a la comunidad académica y a los revisores del presente trabajo a consultar, auditar y reproducir los experimentos a través del repositorio oficial alojado en GitHub:

<https://github.com/aledash3/modelo-estres-devs>

La documentación técnica del repositorio incluye un archivo `README.md` con las instrucciones de ejecución y las dependencias de librerías necesarias para replicar exactamente los mismos coeficientes de regresión reportados en la sección de Resultados.

Referencias

- [1] D. Montgomery, E. Peck y G. Vining, *Introduction to Linear Regression Analysis*, 5th ed., Wiley, 2012.
- [2] M. Kutner, C. Nachtsheim, J. Neter y W. Li, *Applied Linear Statistical Models*, McGraw-Hill, 2005.
- [3] G. James, D. Witten, T. Hastie y R. Tibshirani, *An Introduction to Statistical Learning with Applications in R*, Springer, 2021.
- [4] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, Springer, 2009.
- [5] H. Wickham y G. Grolemund, *R for Data Science*, O'Reilly, 2017.
- [6] M. Graziotin, F. Fagerholm, X. Wang y P. Abrahamsson, "Consequences of unhappiness while developing software," in *International Conference on Evaluation and Assessment in Software Engineering*, 2017.
- [7] N. Forsgren, J. Humble y G. Kim, *Accelerate: The Science of Lean Software and DevOps*, IT Revolution Press, 2018.